Pemetaan Tanaman Pertanian Berbasis Citra Multi-Temporal Sentinel-2 dengan Pendekatan Kombinasi Band Spektral dan Model Semantic Segmentation

TUGAS AKHIR

Diajukan sebagai salah satu syarat untuk memperoleh gelar Sarjana Sains Data pada
Program Studi Sarjana Sains Data
Fakultas Informatika Universitas Telkom

Oleh:
IZZULHAQ MAHARDIKA
1305220010

Pembimbing:
Dr. Gamma Kosala, S.Si
NIP. 21920013

PROGRAM STUDI SARJANA SAINS DATA
FAKULTAS INFORMATIKA
UNIVERSITAS TELKOM
BANDUNG
2025

Lembar Persetujuan

Pemetaan Tanaman Pertanian Berbasis Citra Multi-Temporal Sentinel-2 dengan Pendekatan Kombinasi Band Spektral dan Model Semantic Segmentation

Crop Mapping Based on Multi-Temporal Sentinel-2 Imagery with Spectral Band Combination and Semantic Segmentation Models

Izzulhaq Mahardika
NIM: 1305220010

Tugas Akhir ini diajukan sebagai salah satu syarat untuk memperoleh gelar
Sarjana Sains Data pada
Program Studi Sarjana Sains Data
Fakultas Informatika Universitas Telkom
Bandung, 13 Oktober 2025

Menyetujui,
Pembimbing

Dr. Gamma Kosala, S.Si
NIP. 21920013

Abstrak

Pemetaan tanaman pertanian berperan penting dalam mendukung ketahanan pangan, perencanaan pola tanam, serta pengelolaan sumber daya agrikultur. Citra satelit Sentinel-2 dengan resolusi tinggi spasial dan temporal telah banyak dimanfaatkan dalam klasifikasi tutupan lahan, termasuk untuk identifikasi jenis tanaman. Penelitian ini mengadopsi pendekatan *semantic segmentation* berbasis *deep learning*, yaitu DeepLabV3+ dan SegFormer, untuk mengklasifikasikan tanaman pertanian berdasarkan citra multi-temporal Sentinel-2 dan label dari *Cropland Data Layer* (CDL) milik USDA.

Studi literatur menunjukkan bahwa pendekatan multi-temporal dan kombinasi band spektral dapat meningkatkan akurasi klasifikasi karena mampu menangkap dinamika spektral dan fenologi tanaman. Area studi terletak di Sacramento Valley, California, yang merupakan salah satu kawasan agrikultur paling produktif di Amerika Serikat. Data Sentinel-2 dikumpulkan setiap 15 hari selama periode 2022–2024 dan diproses melalui tahapan *masking* awan, *histogram matching*, *resampling* spasial, normalisasi, dan *patching*.

Evaluasi dilakukan menggunakan metrik *Overall Accuracy*, *Mean Intersection over Union* (mIoU), dan F1-score, serta dilengkapi analisis kesalahan dan waktu inferensi. Penelitian ini juga mengimplementasikan *attention mechanism* pada masing-masing model untuk meningkatkan performa segmentasi. Eksperimen dilakukan dalam beberapa skenario yang menguji pengaruh data multi-temporal dan kombinasi spektral terhadap hasil klasifikasi tanaman. Hasil dari studi ini diharapkan dapat memberikan kontribusi terhadap pengembangan model segmentasi citra multispektral yang lebih akurat dan adaptif terhadap variasi spasial dan temporal tutupan lahan pertanian.

Kata Kunci: Pemetaan Pertanian, Multi-temporal, Band Spektral, Semantic Segmentation

Daftar Isi

1 PENDAHULUAN **7**

1.1 Latar Belakang 7

1.2 Perumusan Masalah 8

1.3 Tujuan 8

1.4 Batasan Masalah 9

1.5 Hipotesis 9

1.6 Rencana Kegiatan 9

1.7 Jadwal Kegiatan 11

2 KAJIAN PUSTAKA **12**

2.1 Pemetaan Tanaman Pertanian 12

2.2 Semantic Segmentation 12

2.2.1 DeepLabV3+ 13

2.2.2 SegFormer 13

2.2.3 Attention Mechanism 13

2.3 Citra Sentinel-2 dan Cropland Data Layer (CDL) 14

2.3.1 Citra Spektral Sentinel-2 14

2.3.2 Pendekatan Multi-Temporal 14

2.3.3 Crop Data Layer (CDL) 15

2.4 Penelitian Terkait 15

3 METODOLOGI DAN DESAIN SISTEM **17**

3.1 Area Studi Sacramento Valley 17

3.2 Pengumpulan Data 17

3.3 Eksplorasi Data 18

3.3.1 Visualisasi Citra 18

3.3.2 Statistik Deskriptif 18

3.3.3 Data Label CDL 18

3.3.4 Histogram per Band dan Korelasi 22

3.3.5 Perubahan Indeks Vegetasi 22

3.4 Data Preprocessing 22
3.4.1 Cloud Masking dan Shadow Masking 22
3.4.2 Citra Komposit Temporal 22
3.4.3 Resampling Citra 22
3.4.4 Histogram Matching 22
3.4.5 Patching dan Normalisasi Citra 23
3.4.6 Seleksi Band Spektral–Temporal 23
3.4.7 Label Filtering 24
3.5 Pelatihan Model 25
3.5.1 Penerapan Attention Mechanism 25
3.5.2 Skenario Pelatihan 25
3.5.3 Hyperparameter Tuning 25
3.6 Evaluasi 25

4 HASIL DAN PEMBAHASAN 26
4.1 Hasil Eksperimen 26
4.2 Analisis Hasil 26
4.2.1 Perbandingan Performa Model 26
4.2.2 Pengaruh Data Multi-Temporal 26
4.2.3 Analisis Kesalahan 26

5 KESIMPULAN DAN SARAN 27
5.1 Kesimpulan 27
5.2 Saran 27

Daftar Tabel

1.1 Jadwal Kegiatan Penelitian 11

2.1 Informasi Band Spektral Sentinel-2 (Earth Engine Data Catalog) 14
2.2 Metode, Kekurangan dan Kelebihan Penelitian Terkait 16

3.1 30 Kelas CDL Teratas Berdasarkan Cakupan Area di Area Studi (2022) 19
3.2 Rekapitulasi Cakupan Lahan berdasarkan Tipe Penggunaan . . 19
3.3 Kelas CDL Terpilih untuk Pelatihan Model ($\geq$ 1% cakupan area studi) 21

Daftar Gambar

2.1 Arsitektur DeepLabV3+ (Chen et al., 2018). 13
2.2 Arsitektur SegFormer. 13

3.1 Distribusi kelas CDL dan strategi seleksi kelas untuk pelatihan model. Kelas dengan cakupan $\geq 1\%$ dipilih sebagai kelas target (hijau), kelas 0,5–1% sebagai kandidat eksperimen lanjutan (oranye), dan kelas $< 0{,}5\%$ dikecualikan (abu-abu). 20

Bab 1

PENDAHULUAN

1.1 Latar Belakang

Pertumbuhan penduduk dunia dan meningkatnya standar hidup telah mendorong perluasan serta intensifikasi pemanfaatan lahan pertanian secara global untuk memenuhi permintaan pangan dan komoditas yang terus meningkat (Potapov et al., 2022). Pengembangan peta sebaran tanaman secara akurat dan skala besar menjadi penting untuk memastikan ketahanan pangan dan merencakanan pola tanam di masa depan (Gao et al., 2023). Informasi spasial mengenai sebaran dan jenis tanaman pertanian sangat dibutuhkan untuk estimasi hasil panen, mengelola irigasi, serta merencanakan distribusi komoditas (Yi et al., 2020).

Satelit penginderaan jauh menyediakan citra resolusi tinggi yang dapat dimanfaatkan untuk pemetaan lahan pertanian secara luas dan otomatis, sebagai alternatif metode survei lapangan konvensional yang memakan waktu dan biaya tinggi (Li et al., 2023a). Satelit Sentinel-2 digunakan untuk pemetaan lahan pertanian karena menyediakan citra dengan resolusi tinggi hingga 10 meter dan resolusi temporal pada 5 hari (Phiri et al., 2020). Sentinel-2 memiliki hingga 13 band spektral yang dapat dimanfaatkan untuk fitur pada klasifikasi lahan pertanian (Yi et al., 2020). Penggunaan Cropland Data Layer (CDL) yang disediakan oleh United States Department of Agriculture (USDA) sebagai data label dapat meningkatkan validitas pemetaan tanaman karena menyediakan label hingga tingkat piksel dengan resolusi 30 meter dan cakupan spasial yang luas (Maleki et al., 2024).

Kemajuan dalam bidang *computer vision* (CV) dan *deep learning* menciptakan pergeseran dalam analisis penginderaan jauh menuju metode *semantic segmentation* (Luo et al., 2024). Berbeda dengan klasifikasi piksel-per-piksel biasa, *semantic segmentation* mengelompokkan piksel dengan kelas tutupan lahan tertentu secara bersamaan (Ajibola and Cabral, 2024). Algoritma *se-*

mantic segmentation seperti DeepLabV3+ dan SegFormer mulai diadopsi untuk klasifikasi tanaman pertanian (Li et al., 2023a). Model segmentasi lainnya seperti DeepLabV3+ dan SegFormer juga telah diterapkan, salah satunya oleh Li (2023), yang menunjukkan bahwa kedua model tersebut mampu menghasilkan akurasi segmentasi tinggi (Li et al., 2023a; Hsu et al., 2022; Chang et al., 2023).

Meskipun demikian, beberapa penelitian fokus pada penggunaan citra indeks vegetasi (NDVI, EVI) tanpa mempertimbangkan keunggulan seluruh band spektral (Gao et al., 2023; Thorp and Drajat, 2021; Seydi et al., 2022). Padahal, kombinasi fitur spektral yang dipilih dengan metode *feature selection* dapat meningkatkan pemisahan kelas tanaman (Yi et al., 2020). Oleh karena itu, diperlukan eksperimen untuk menentukan kombinasi band dan multispektral yang optimal, sehingga proses pemetaan tanaman pertanian dapat lebih akurat.

Pengembangan model *semantic segmentation* berbasis citra satelit memerlukan data label yang akurat hingga level piksel. Namun, di Indonesia belum tersedia dataset publik untuk identifikasi jenis tanaman pertanian. Untuk mengatasi masalah tersebut, area studi pada penelitian ini difokuskan di kawasan Sacramento Valley, California di Amerika Serikat yang didukung oleh ketersediaan dataset publik Cropland Data Layer (CDL).

1.2 Perumusan Masalah

Berikut adalah rumusan masalah pada penelitian ini:

1. Bagaimana pengaruh dari data multi-temporal pada akurasi pemetaan tanaman?

2. Bagaimana pengaruh dari kombinasi band spektral yang berbeda pada kinerja model *semantic segmentation*?

3. Bagaimana kinerja dari beberapa model *semantic segmentation*, DeepLabV3+, dan SegFormer untuk klasifikasi tanaman pertanian?

1.3 Tujuan

Berdasarkan rumusan masalah yang telah disebutkan, tujuan penelitian ini adalah sebagai berikut:

1. Mengevaluasi pengaruh dari data multi-temporal pada akurasi pemetaan tanaman.

2. Menilai pengaruh dari kombinasi band spektral yang berbeda pada kinerja model *semantic segmentation*.

3. Membandingkan kinerja dari tiga model *semantic segmentation*, DeepLabV3+, dan SegFormer, untuk mengklasifikasikan tanaman pertanian pada citra Sentinel-2.

1.4 Batasan Masalah

Batasan masalah pada penelitian ini adalah sebagai berikut:

1. Penelitian ini menggunakan data sekunder dari platform Google Earth Engine (GEE). Dataset terdiri dari atas citra Sentinel-2 sebagai input dan Cropland Data Layer (CDL) sebagai data label, dengan periode pengambilan antara tahun 2022 hingga 2024.

2. Area studi terletak di kawasan Sacramento Valley, California pada koordinat geografis (122°18′36″ BB hingga 121°20′26″ BB, 38°41′7″ LU hingga 39°49′47″ LU) dengan total luas area 10.629,25 km^2.

1.5 Hipotesis

Berdasarkan temuan studi terdahulu, hipotesis yang diajukan dalam penelitian ini adalah sebagai berikut:

- Penggunaan citra multi-temporal dengan kombinasi band spektral menghasilkan dataset yang kaya akan fitur, sehingga akan menghasilkan akurasi pemetaan pertanian yang lebih tinggi dibandingkan penggunaan citra *single-date* atau hanya menggunakan indeks vegetasi.

- Model *semantic segmentation* dengan *attention mechanism* dihipotesiskan memiliki performa lebih baik daripada model tanpa attention (*baseline*), karena kemampuannya dalam memfokuskan pada fitur-fitur penting.

1.6 Rencana Kegiatan

Untuk mencapai tujuan yang telah ditentukan, penelitian ini akan dilaksanakan melalui tahapan kegiatan sebagai berikut:

1. **Studi Literatur dan Perumusan Metode**
   Melakukan kajian pustaka yang relevan terkait pemetaan tanaman pertanian dengan citra satelit, pemanfaatan citra multi-temporal, pemilihan

dan kombinasi band spektral Sentinel-2, dan model *semantic segmentation* khususnya DeepLabV3+, dan SegFormer. Berdasarkan kajian ini, dirumuskan kesenjangan penelitian dan kerangka metodologi penelitian.

2. **Pengumpulan Data**
   Mengambil data citra multi-temporal Sentinel-2 untuk area studi di Sacramento Valley dengan spektral band B2, B3, B4, B5, B7, B8, B11, dan B12 dengan interval komposit 15 hari selama setahun penuh pada tahun 2022, 2023, dan 2024. Selain itu, data label diambil dari Cropland Data Layer (CDL) yang disediakan oleh USDA NASS.

3. **Preprocessing Data**
   Melakukan tahap preprocessing citra yang mencakup *cloud masking* dan *shadow masking*, *resampling* dan projection citra Sentinel-2 dan CDL, normalisasi nilai reflectance, pemilihan kombinasi band spektral optimal menggunakan metode *feature selection* berbasis global separation index, dan patching citra dan label menjadi patch berukuran 256×256 piksel serta filter labeling untuk patch selain jenis tanaman pertanian.

4. **Pelatihan Model Semantic Segmentation**
   Melatih dan membangingkan performa tiga arsitektur *semantic segmentation*, yaitu DeepLabV3+, dan SegFormer pada dataset yang telah diproses. Beberapa skenario training akan dilakukan untuk membandingkan pengaruh konfigurasi band dan temporal terhadap hasil segmentasi. Untuk setiap model, akan ditambahkan juga *attention mechanism* untuk meningkatkan kemampuan model dalam menyoroti fitur penting.

5. **Evaluasi dan Analisis Hasil**
   Evaluasi utama dilakukan menggunakan metrik evaluasi segmentasi seperti *mean Intersection over Union* (mIoU), *Overall Accuracy* (OA), dan F1-score. Selain evaluasi utama, akan dilakukan evaluasi tambahan berupa *error analysis* dan pengukuran *inference time*. Analisis hasil mencakup perbandingan antar model, pengaruh kombinasi band, serta pengaruh penggunaan data multi-temporal. Visualisasi segmentasi dan distribusi prediksi kelas juga dianalisis untuk mendukung interpretasi hasil kuantitatif.

6. **Penyusunan Laporan Akhir**
   Menyusun laporan akhir tugas akhir yang berisi latar belakang, metodo-

logi, implementasi teknis, hasil eksperimen, analisis, serta simpulan dan rekomendasi berdasarkan hasil penelitian.

1.7 Jadwal Kegiatan

Jadwal pelaksanaan seluruh kegiatan penelitian dapat dilihat pada Tabel 1.1.

Tabel 1.1: Jadwal Kegiatan Penelitian

Kegiatan	**Bulan 1**	**Bulan 2**	**Bulan 3**	**Bulan 4**	**Bula**
Studi Literatur dan Perumusan Metode	✓				
Pengumpulan Data	✓	✓			
Preprocessing Data		✓	✓		
Pelatihan Model Semantic Segmentation			✓	✓	
Evaluasi dan Analisis Hasil				✓	✓
Penyusunan Laporan Akhir					✓

Bab 2

KAJIAN PUSTAKA

2.1 Pemetaan Tanaman Pertanian

Pemetaan tanaman pertanian adalah proses mengidentifikasi dan memetakan sebaran lahan pertanian dengan berbagai jenis komoditas, seperti padi, jagung, dan kedelai hingga varietas dan intensitas tanam (Alami Machichi et al., 2023). Tujuan pemetaan ini adalah untuk menyediakan informasi spasial dalam perencaan produksi, estimasi hasil, maupun kebijakan pengelolaan lahan. Pemetaan dapat berbentuk klasifikasi banyak jenis tanaman, pemetaan varietas spesifik, pemetaan biner *cropland* dan *non-cropland*, atau analisis khusus seperti fase pertumbuhan (Alami Machichi et al., 2023).

Selama dua dekade terakhir, riset tentang pemetaan tanaman dengan penginderaan jauh berbasis citra satelit semakin meningkat (Weiss et al., 2020). Beragam model *supervised machine learning* seperti Random Forest, SVM, hingga *neural network* menunjukkan kinerja yang tinggi dalam mengidentifikasi komoditas pada citra resolusi tinggi (Zhao et al., 2020). Kemunculan metode ini membuat proses pembuatan peta lahan lebih cepat dan efisien dibanding metode lapangan konvensional (Alami Machichi et al., 2023).

2.2 Semantic Segmentation

Semantic segmentation adalah teknik dalam pemrosesan citra yang mengelompokkan piksel pada gambar ke dalam kelas tertentu yang bermakna secara semantik. Setiap piksel dalam gambar dibeli label yang menunjukkan kategori tertentu yang menghasilkan peta segmentasi yang detail (Luo et al., 2024). Dalam penginderaan jauh untuk pertanian presisi, *semantic segmentation* digunakan untuk pemetaan tanaman pertanian, klasifikasi, dan pemantauan lahan (Ajibola and Cabral, 2024). Terdapat metode *semantic segmentation* tradisional sebelum *neural network* diciptakan, yaitu metode *threshold*, *clustering*,

wavelet transform, dan *random forest* (Luo et al., 2024), setelah itu muncul metode-metode berbasis *deep learning* seperti DeepLabV3+, dan SegFormer.

2.2.1 DeepLabV3+

DeepLabV3+ merupakan model segmentasi berbasis CNN yang diperkenalkan oleh Chen et al. (2018). Arsitektur DeepLabV3+ menambahkan modul Atrous Spatial Pyramid Pooling (ASPP) yang menggunakan konvolusi atrous (dilated) dengan skala berbeda untuk menangkap konteks dari berbagai ukuran objek tanpa kehilangan resolusi. Model ini juga dilengkapi dengan modul decoder untuk mengembalikan detail spasial yang hilang dalam proses ekstraksi fitur, sehingga hasil segmentasi piksel lebih halus dan akurat (Chen et al., 2018). Model DeepLabV3+ telah digunakan dalam beberapa penelitian pemetaan lahan pertanian dengan metode *semantic segmentation* (Chang et al., 2023; Li et al., 2023a; Cheng et al., 2023).

Gambar 2.1: Arsitektur DeepLabV3+ (Chen et al., 2018).

2.2.2 SegFormer

SegFormer adalah model segmentasi berbasis transformer yang mengombinasikan kemampuan menangkap konteks global melalui mekanisme *self-attention* dengan desain yang efisien dan sederhana. Berbeda dari arsitektur vision Transformer lain, SegFormer menggunakan encoder Transformer bertingkat (hierarchical) tanpa komponen *positional encoding*, sehingga dapat menerima input citra berukuran arbitrer dan tetap efektif. Decoder SegFormer sangat ringan karena berbasis MLP (*multi-layer perceptron*) yang mengambil fitur multi-level dari encoder untuk menghasilkan peta segmentasi akhir. Beberapa studi pemetaan pertanian telah memanfaatkan SegFormer sebagai metode *semantic segmentation* yang andal dalam mengklasifikasikan kelas tanaman (Li et al., 2023a; Wu et al., 2025).

Gambar 2.2: Arsitektur SegFormer.

2.2.3 Attention Mechanism

Attention mechanism adalah komponen dalam *deep learning* yang dirancang untuk meningkatkan fokus model terhadap fitur-fitur penting dalam input data. Dalam konteks *semantic segmentation* pada citra satelit, *attention mecha-*

nism memungkinkan model untuk memberikan bobot lebih besar pada area gambar yang relevan, seperti pola spektral khas dari tanaman tertentu, dan mengabaikan area yang kurang informatif seperti awan atau latar belakang (Niu et al., 2021).

2.3 Citra Sentinel-2 dan Cropland Data Layer (CDL)

2.3.1 Citra Spektral Sentinel-2

Sentinel-2 adalah misi satelit penginderaan jauh dari program Copernicus yang diluncurkan oleh European Space Agency (ESA) yang bertujuan untuk menyediakan data resolusi tinggi untuk pemantauan tutupan dan penggunaan lahan, perubahan iklim, dan bencana alam. Satelit ini dilengkapi dengan sensor multispektral untuk merekam 13 band spektral dengan cakupan luas dan resolusi spasial mencapai 10 hingga 20 meter (Phiri et al., 2020). Penjelasan masing-masing band spektral dapat dilihat pada Tabel 2.1. Citra Sentinel-2 telah digunakan pada beberapa penelitian terkait pemetaan lahan pertanian, Yi et al. (2020) melakukan klasifikasi tanaman pada wilayah Shiyang, Tiongkok dengan memanfaatkan citra Sentinel-2 (Yi et al., 2020). Selain itu, Li et al. (2023) juga menggunakan citra Sentinel-2 untuk segmentasi lahan pertanian di Hetao, Tiongkok (Li et al., 2023a).

Tabel 2.1: Informasi Band Spektral Sentinel-2 (Earth Engine Data Catalog)

Band	**Nama**	**Panjang Gelombang (nm)**	**Res. (m)**	**Fungsi Umum**
B2	Blue	490	10	Deteksi air, bayangan, kor
B3	Green	560	10	Indikasi kesehatan vegetas
B4	Red	665	10	Deteksi klorofil; dasar ND
B5	Red Edge 1	705	20	Deteksi awal stres tanama
B6	Red Edge 2	740	20	Klorofil tinggi, pemantaua
B7	Red Edge 3	783	20	Pemetaan vegetasi padat,
B8	NIR	842	10	Struktur vegetasi, biomass
B11	SWIR 1	1610	20	Kelembaban tanah, deteks
B12	SWIR 2	2190	20	Kandungan air tanaman,

2.3.2 Pendekatan Multi-Temporal

Pendekatan multi-temporal merupakan strategi umum dalam pengolahan citra satelit untuk menangkap dinamika vegetasi sepanjang waktu. Dalam konteks

pemetaan tanaman, pendekatan ini dilakukan dengan memanfaatkan serangkaian citra yang diambil secara berkala, biasanya dalam interval tetap seperti setiap 10 hingga 16 hari. Pola pengambilan ini memungkinkan pemantauan perubahan spektral tanaman pada berbagai fase pertumbuhan, mulai dari tahap vegetatif, berbunga, hingga panen. Dengan demikian, variasi fenologis antar jenis tanaman dapat dikenali lebih akurat dibandingkan dengan penggunaan citra pada satu waktu saja. Pendekatan ini terbukti meningkatkan akurasi klasifikasi karena tanaman berbeda menunjukkan respons spektral yang berbeda pula pada setiap tahap pertumbuhannya (Li et al., 2023a; Yi et al., 2020; Li et al., 2023b).

2.3.3 Crop Data Layer (CDL)

Cropland Data Layer (CDL) adalah produk klasifikasi tutupan lahan yang dikembangkan oleh United States Department of Agriculture (USDA) melalui National Agricultural Statistics Service (NASS). Dataset ini ditujukan untuk memetakan area pertanian di Amerika Serikat dengan cakupan hingga 149 kelas tutupan lahan, mencakup berbagai jenis tanaman pertanian utama seperti jagung, gandum, dan padi, serta kategori non-pertanian seperti hutan, perairan, dan permukiman (Copenhaver et al., 2021). Saat ini, CDL menyediakan data label dengan resolusi spasial 30 meter (Tran et al., 2022). Dalam pemetaan lahan pertanian, CDL berperan penting sebagai sumber referensi atau *ground truth* untuk pelatihan dan evaluasi model klasifikasi berbasis citra penginderaan jauh (Copenhaver et al., 2021).

2.4 Penelitian Terkait

Terdapat beberapa penelitian sebelumnya yang mengkaji tentang penggunaan citra multi-temporal dan multi-spektral sebagai metode untuk pemetaan lahan pertanian. Yi et al. (2020) memanfaatkan citra Sentinel-2 multi-temporal pada musim tanam 2019 dengan area studi di Shiyang, China (Yi et al., 2020). Pengujian dilakukan dengan mengkombinasikan fitur spektral dan temporal pada model Random Forest, yang menunjukkan peningkatan signifikan pada akurasi klasifikasi dengan OA mencapai 0,94. Berdasarkan temuan Li et al. (2023), kombinasi informasi temporal saja tidak cukup untuk mencapai akurasi tinggi, karena cenderung menghasilkan noise yang memengaruhi klasifikasi berbasis piksel. Penambahan fitur spektral terbukti berkontribusi positif pada performa klasifikasi model *deep learning* (Li et al., 2023b).

Gao et al. (2023) memperkenalkan A2SegNet, model *semantic segmentation* dengan *attention mechanism* untuk memetakan jagung dan kedelai dari citra Sentinel-2. Model ini mampu mengekstraksi fitur spasial-spektral tanaman dan unggul dibanding model baseline SegNet (Gao et al., 2023). Model segmentasi lain juga mulai digunakan, seperti DeepLabV3+ dan SegFormer pada penelitian yang dilakukan oleh Li (2023), akurasi segmentasi dari DeepLabV3+ dan SegFormer terbukti baik mencapai 88,28% (Li et al., 2023a).

Penelitian mengenai pemetaan tanaman pertanian menggunakan penginderaan jauh dengan metode *semantic segmentation* sudah beberapa kali dilakukan. Namun, eksplorasi mengenai kombinasi optimal band spektral belum banyak dilakukan. Rincian lebih lanjut terkait kelebihan dan kekurangan penelitian terkait dapat dilihat pada Tabel 2.2.

Tabel 2.2: Metode, Kekurangan dan Kelebihan Penelitian Terkait

Pustaka	**Metode**	**Kelebihan dan Kekurangan**
(Gao et al., 2023)	Improv. SegNet (A2SegNet) + CBAM. 6 Band S2 + NDVI/EVI	(+) Adaptif tangkap spasial thn berbeda. (-) Lingkup 2 kelas (jagung/kedelai).
(Li et al., 2023a)	U-Net, DeepLabV3+, SegFormer. Multi-temporal S2.	(+) Multi-temporal kurangi efek awan. (-) Fokus 4 jenis tanaman.
(Yi et al., 2020)	RF Classifier. Multi-band S2.	(+) Akurasi tinggi (95% OA). (-) Berbasis patch/pixel, bkn segmentasi.

Bab 3

METODOLOGI DAN DESAIN SISTEM

3.1 Area Studi Sacramento Valley

Area studi penelitian ini adalah Sacramento Valley dalam daerah Central Valley, California, pada koordinat geografis (122°4′41″ BB hingga 121°34′31″ BB, 38°45′14″ LU hingga 39°10′29″ LU) dengan total luas area 2.038,08 km^2. Kawasan ini memiliki bentang alam dan jenis tanaman yang sangat beragam karena variasi iklim dan topografinya, juga menjadi salah satu wilayah pertanian paling produktif di Amerika Serikat dengan jenis tanaman pertanian yang beragam. Iklim di wilayah ini termasuk minim hujan di musim panas, sehingga memungkinkan pengamatan spektral tanaman sepanjang musim tanam (Yuan and Lin, 2021).

3.2 Pengumpulan Data

Data pada penelitian ini menggunakan citra satelit Sentinel-2 dan data label tutupan lahan dari Cropland Data Layer (CDL). Data citra diambil dari koleksi Sentinel-2 Surface Reflectance (COPERNICUS/S2_SR_HARMONIZED) melalui platform Google Earth Engine (GEE) dengan batas persentase awan kurang dari 10% pada area studi. Citra dikumpulkan secara multi-temporal sepanjang tahun 2022, 2023, dan 2024 dengan interval pengambilan setiap 15 hari sekali. Periode akuisisi mencakup satu tahun penuh, menghasilkan total 72 citra komposit yang terdiri dari 24 citra pada 2022, 23 citra pada 2023, dan 25 citra pada 2024. Terdapat tiga interval citra yang melebihi batas persentase awan, sehingga tidak digunakan sebagai dataset.

Untuk mendapatkan citra multispektral, dipilih sembilan band (B2, B3, B4, B5, B6, B7, B8, B11, B12) yang relevan terhadap karakteristik vegetasi. Sementara itu, data label diperoleh dari dataset CDL tahun 2022, 2023, dan 2024 yang diunduh melalui situs resmi USDA NASS yang terdiri dari 134 kelas

dengan resolusi spasial 30 meter per piksel.

3.3 Eksplorasi Data

3.3.1 Visualisasi Citra

Visualisasi citra Sentinel-2 mencakup citra True Color (RGB) yang merupakan representasi visual yang tampak pada mata manusia berdasarkan Band B4 (Red), Band B3 (Green), dan Band B2 (Blue). Selain itu, ditampilkan juga band multispektral yang digunakan untuk menyoroti perbedaan pantulan (*reflectance*) pada panjang gelombang tertentu.

3.3.2 Statistik Deskriptif

Setiap citra mencakup sekitar 11.810.282 piksel. Pada data preprocessing, akan dilakukan pembagian patch berukuran 256×256 piksel, sehingga setiap citra akan menghasilkan sekitar 180 patch. Total citra yang diambil dari tahun 2022–2024 adalah 72 citra, sehingga akan diperoleh total 12.960 patch.

3.3.3 Data Label CDL

Dataset CDL tahun 2022 pada area studi memiliki 72 kelas aktif yang terbagi menjadi 48 kelas tanaman (*cropland*) dan 16 kelas non-tanaman (permukiman, perairan, lahan basah, semak, dan lainnya). Lahan pertanian (*cropland*) mencakup 83,8% dari total area studi, sedangkan sisanya (16,2%) merupakan lahan non-pertanian. Label CDL menggunakan proyeksi EPSG:5070 (NAD83/Conus Albers) dengan resolusi spasial 30 meter per piksel, sedangkan Sentinel-2 menggunakan proyeksi EPSG:4326 (WGS84) dengan resolusi spasial $\approx$10 meter per piksel, sehingga diperlukan proses reprojektion dan *resampling* sebelum digunakan sebagai label pelatihan.

Distribusi Kelas CDL di Area Studi

Distribusi kelas CDL pada area studi dianalisis berdasarkan jumlah piksel hasil reprojektion ke grid Sentinel-2 (5.596×4.684 piksel, ukuran piksel $7{,}78 \times 10{,}00$ $m^2 \approx 77{,}8$ m^2/piksel). Tabel 3.1 menyajikan 30 kelas dengan cakupan tertinggi beserta konversinya ke satuan hektar dan kilometer persegi.

Rekapitulasi berdasarkan tipe penggunaan lahan disajikan pada Tabel 3.2.

Tabel 3.1: 30 Kelas CDL Teratas Berdasarkan Cakupan Area di Area Studi (2022)

No.	Nama Kelas	ID	Piksel	Area (ha)	Area (km^2)
1	Fallow/Idle Cropland	61	7.426.247	57.742,5	577,42
2	Almonds	75	3.011.056	23.412,3	234,12
3	Walnuts	76	2.387.806	18.566,3	185,66
4	Tomatoes	54	1.942.579	15.104,4	151,04
5	Rice	3	1.731.503	13.463,2	134,63
6	Grass/Pasture	176	1.359.253	10.568,8	105,69
7	Winter Wheat	24	1.231.983	9.579,2	95,79
8	Sunflower	6	913.565	7.103,4	71,03
9	Developed/Low Intensity	122	632.042	4.914,4	49,14
10	Alfalfa	36	575.672	4.476,1	44,76
11	Developed/Med Intensity	123	570.466	4.435,6	44,36
12	Plums	220	560.637	4.359,2	43,59
13	Developed/Open Space	121	536.853	4.174,3	41,74
14	Herbaceous Wetlands	195	381.008	2.962,5	29,63
15	Other Hay/Non Alfalfa	37	375.842	2.922,3	29,22
16	Open Water	111	331.675	2.578,9	25,79
17	Grapes	69	327.883	2.549,4	25,49
18	Safflower	33	240.323	1.868,6	18,69
19	Pistachios	204	203.826	1.584,8	15,85
20	Woody Wetlands	190	173.782	1.351,2	13,51
21	Developed/High Intensity	124	127.919	994,6	9,95
22	Watermelons	48	118.805	923,8	9,24
23	Oats	28	96.406	749,6	7,50
24	Shrubland	152	95.610	743,4	7,43
25	Barley	21	88.582	688,8	6,89
26	Corn	1	86.009	668,8	6,69
27	Olives	211	77.289	601,0	6,01
28	Prunes	210	76.737	596,7	5,97
29	Dry Beans	42	64.263	499,7	5,00
30	Other Crops	44	63.890	496,8	4,97
	(+42 kelas minor)			*cakupan gabungan <3%*	
	Total		**26.211.664**	**203.807,7**	**2.038,08**

Tabel 3.2: Rekapitulasi Cakupan Lahan berdasarkan Tipe Penggunaan

Tipe Lahan	Area (ha)	Area (km^2)	%
Tanaman aktif (annual & perennial crops)	≈103.000	≈1.030	50,5%
Lahan bero (*Fallow/Idle*)	57.742	577	28,3%
Non-pertanian (permukiman, air, lahan basah, semak)	≈43.000	≈430	21,2%
Total	**203.808**	**2.038**	**100%**

Seleksi Kelas Optimal untuk Pelatihan Model

Dari 72 kelas CDL yang teridentifikasi di area studi, dilakukan seleksi kelas untuk pelatihan model berdasarkan ambang batas cakupan area minimum $\geq 1\%$ dari total area studi. Visualisasi distribusi kelas dan strategi seleksi ditampilkan pada Gambar 3.1.

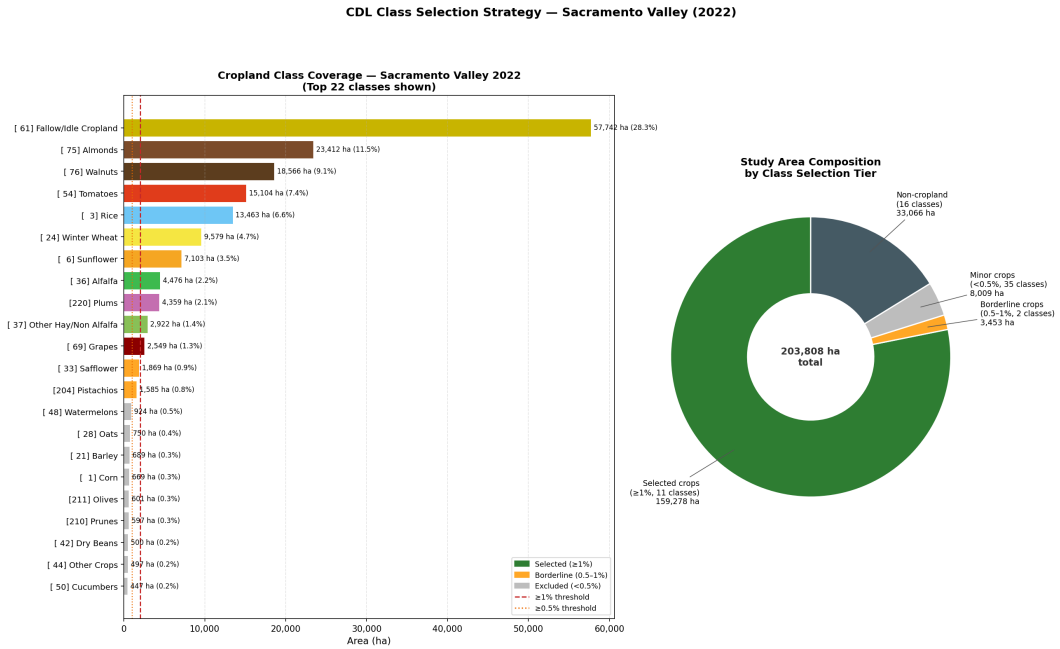

Gambar 3.1: Distribusi kelas CDL dan strategi seleksi kelas untuk pelatihan model. Kelas dengan cakupan $\geq 1\%$ dipilih sebagai kelas target (hijau), kelas 0,5–1% sebagai kandidat eksperimen lanjutan (oranye), dan kelas $< 0{,}5\%$ dikecualikan (abu-abu).

Tabel 3.3 menampilkan 11 kelas yang terpilih beserta justifikasinya.

Terdapat tiga justifikasi ilmiah untuk ambang batas $\geq 1\%$ yang digunakan:

1. **Kecukupan sampel untuk *deep learning*.** Kelas dengan cakupan $\geq 1\%$ menempati ≥ 2.038 ha di area studi. Pada ukuran patch 256×256 piksel dengan resolusi 10 m (≈ 510 ha/patch), cakupan tersebut menghasilkan representasi spasial yang memadai dari ratusan petak lahan pertanian yang berbeda, sehingga model dapat mempelajari fitur spektral dan spasial yang dapat digeneralisasi. Kelas di bawah 1% (<2.000 ha) umumnya tampil sebagai fragmen poligon yang tersebar dan kecil, sehingga tidak menyediakan keragaman spasial yang cukup untuk pelatihan segmentasi berbasis CNN (Alami Machichi et al., 2023).

2. **Ketidakseimbangan kelas yang dapat ditangani.** Himpunan kelas terpilih menghasilkan rasio ketidakseimbangan maksimum sebesar 22,6:1

Tabel 3.3: Kelas CDL Terpilih untuk Pelatihan Model ($\geq$ 1% cakupan area studi)

No.	Kelas	ID	% Tanaman	Area (ha)	Area (km^2)
1	Fallow/Idle Cropland	61	33,8%	57.742	577,42
2	Almonds	75	13,7%	23.412	234,12
3	Walnuts	76	10,9%	18.566	185,66
4	Tomatoes	54	8,8%	15.104	151,04
5	Rice	3	7,9%	13.463	134,63
6	Winter Wheat	24	5,6%	9.579	95,79
7	Sunflower	6	4,2%	7.103	71,03
8	Alfalfa	36	2,6%	4.476	44,76
9	Plums	220	2,6%	4.359	43,59
10	Other Hay/Non Alfalfa	37	1,7%	2.922	29,22
11	Grapes	69	1,5%	2.549	25,49
–	Background (lainnya)	0	–	–	–
Total kelas terpilih			**93,3%**	**159.278**	**1.592,8**

(Fallow 57.742 ha vs. Grapes 2.549 ha). Rasio ini masih dapat ditangani dengan teknik standar seperti *inverse-frequency class weighting* atau *Focal Loss* tanpa menyebabkan ketidakstabilan pelatihan. Memasukkan kelas di bawah 0,5% akan mendorong rasio ini di atas 100:1, yang melampaui kemampuan koreksi teknik pembobotan standar (Luo et al., 2024).

3. **Relevansi pertanian Sacramento Valley.** Kesebelas kelas yang terpilih merepresentasikan komoditas pertanian dominan Sacramento Valley berdasarkan statistik produksi tahunan USDA NASS (Copenhaver et al., 2021): *Almonds* dan *Walnuts* merupakan tanaman pohon utama California yang bersama-sama mencakup 420 km^2; *Tomatoes* mencerminkan posisi Sacramento Valley sebagai pusat produksi tomat olahan; *Rice* memiliki tanda spektral yang khas akibat periode penggenangan sawah; dan *Fallow/Idle Cropland* penting untuk pemantauan rotasi tanaman dan intensitas pertanian (Maleki et al., 2024).

Dua kelas tambahan, yaitu *Safflower* (ID 33, 0,92%) dan *Pistachios* (ID 204, 0,78%), berada di batas ambang dan akan dievaluasi dalam eksperimen lanjutan dengan 13 kelas untuk menilai apakah fenologi khasnya dapat mengompensasi jumlah sampel yang lebih kecil.

3.3.4 Histogram per Band dan Korelasi

Distribusi nilai reflectance dari band B2, B3, dan B4 terkonsentrasi di bawah 2000. Band *red edge* (B5, B6, B7) memiliki distribusi lebih besar. Band NIR (B8) menunjukkan reflectance tinggi dengan distribusi yang lebih merata. Korelasi antar band cahaya tampak (B2, B3, B4) sangat tinggi ($\geq 0,94$).

3.3.5 Perubahan Indeks Vegetasi

NDVI meningkat pada bulan April dan Juli yang menandakan awal musim tanam, lalu turun kembali menjelang akhir tahun yang mengindikasikan masa panen.

3.4 Data Preprocessing

Tahap preprocessing data bertujuan untuk memastikan citra satelit dan data label tutupan lahan memiliki kualitas spasial dan spektral yang konsisten.

3.4.1 Cloud Masking dan Shadow Masking

Tahap awal adalah *cloud masking* dan *shadow masking* pada citra Sentinel-2 menggunakan fungsi bawaan GEE berdasarkan persentase tutupan awan (CLOUDY_PIXEL_PERCENTAGE) yang rendah ($\leq 10\%$).

3.4.2 Citra Komposit Temporal

Citra dikompositkan secara temporal menggunakan fungsi *median reducer* untuk menghasilkan satu citra per interval 15 hari.

3.4.3 Resampling Citra

Dilakukan proses *resampling* spasial menggunakan metode *nearest neighbour* untuk menyamakan resolusi dan sistem proyeksi antara citra Sentinel-2 (10m) dan data label CDL (30m).

3.4.4 Histogram Matching

Metode *histogram matching* diterapkan pada masing-masing band citra Sentinel-2 untuk menyamakan kontras warna piksel dengan label sama (Wang et al., 2023).

3.4.5 Patching dan Normalisasi Citra

Citra dan data label dipotong menjadi patch berukuran 256×256 piksel. Setiap patch dinormalisasi menggunakan *min-max normalization* ke rentang 0 hingga 1:

$$x_{norm} = \frac{x - x_{min}}{x_{max} - x_{min}} \tag{3.1}$$

3.4.6 Seleksi Band Spektral–Temporal

Penelitian ini mengusulkan metode seleksi fitur tiga tahap (*3-stage feature selection*) yang dirancang khusus untuk citra Sentinel-2 multi-temporal pada tugas *semantic segmentation*. Tujuannya adalah mengurangi redundansi spektral dan temporal tanpa mengorbankan performa segmentasi, sekaligus menekan biaya komputasi pelatihan model.

Tahap 1 — Filter Preselection

Tahap pertama bertujuan mereduksi seluruh channel masukan menjadi sekitar 25 kandidat terbaik menggunakan dua ukuran statistik yang murah secara komputasi.

Global Separation Index (GSI). Untuk setiap band b, dihitung nilai separabilitas antar kelas:

$$SI_{s,o}^{(b)} = \frac{|\mu_s^{(b)} - \mu_o^{(b)}|}{1{,}96 \times (\sigma_s^{(b)} + \sigma_o^{(b)})} \tag{3.2}$$

di mana μ_s, σ_s adalah rata-rata dan standar deviasi kelas s, dan μ_o, σ_o untuk kelas pembanding o. Nilai GSI merupakan rata-rata $SI_{s,o}$ atas seluruh pasangan kelas.

RF Feature Importance. Nilai kepentingan fitur diperoleh dari Random Forest yang dilatih pada sampel piksel berlabel:

$$\mathrm{RF}_b = \frac{\Delta\mathrm{impurity}_b}{\sum_{b'} \Delta\mathrm{impurity}_{b'}} \tag{3.3}$$

Joint Score. Kedua skor dinormalisasi ke rentang $[0, 1]$ lalu digabungkan:

$$\mathrm{Score}_b = \alpha \cdot \mathrm{GSI}_{\mathrm{norm},b} + (1 - \alpha) \cdot \mathrm{RF}_{\mathrm{norm},b} \tag{3.4}$$

dengan $\alpha = 0{,}5$ (bobot seimbang). Band dengan skor Score_b tertinggi dipilih sebagai kandidat Tahap 2.

Tahap 2 — CNN Forward Selection

Tahap kedua menggunakan model segmentasi ringan (U-Net dengan encoder ResNet-18) sebagai *oracle* seleksi. Algoritma *sequential forward selection* secara greedy menambahkan band satu per satu berdasarkan urutan *joint score* dari Tahap 1, dan mempertahankan band tersebut hanya apabila mIoU validasi meningkat melebihi ambang batas δ:

$$\text{terima band } b \iff \text{mIoU}_{t+1} > \text{mIoU}_t + \delta \tag{3.5}$$

dengan $\delta = 0{,}005$. Proses dihentikan apabila tidak terjadi peningkatan selama tiga penambahan berturut-turut, atau jumlah band mencapai batas maksimum. Setiap iterasi melatih model selama 15 epoch dengan *early stopping* (patience = 5) untuk efisiensi komputasi.

Metode ini merupakan kontribusi baru yang membedakan penelitian ini dari pendekatan sebelumnya. Pada studi terdahulu (Li et al., 2023c), seleksi band dilakukan menggunakan GSI dan eliminasi fitur berbasis Random Forest sebagai *filter* statis, di mana model segmentasi hanya digunakan setelah proses seleksi selesai. Dalam penelitian ini, model segmentasi sendiri bertindak sebagai *oracle* dalam loop seleksi, sehingga kriteria pemilihan fitur sepenuhnya dioptimalkan terhadap metrik segmentasi (mIoU) daripada metrik klasifikasi piksel.

Tahap 3 — Validasi Model Penuh

Tiga himpunan band dilatih menggunakan tiga arsitektur segmentasi penuh untuk mengevaluasi dampak seleksi:

1. **Eksperimen A** — semua band (baseline)
2. **Eksperimen B** — band pilihan Tahap 1 (filter saja)
3. **Eksperimen C** — band pilihan Tahap 2 (CNN forward selection)

Setiap eksperimen dilatih dengan U-Net, DeepLabV3+, dan SegFormer selama 100 epoch. Metrik yang dibandingkan meliputi mIoU, IoU per kelas, F1-score, waktu pelatihan per epoch, dan penggunaan memori GPU.

3.4.7 Label Filtering

Berdasarkan seleksi kelas yang dijelaskan pada Subbagian 3.3.3, diterapkan proses *label filtering* pada data CDL. Sebelas kelas tanaman dengan cakupan

$\geq$ 1% (ID: 3, 6, 24, 36, 37, 54, 61, 69, 75, 76, 220) dipertahankan sebagai kelas target, sedangkan seluruh kelas lainnya—termasuk perairan, permukiman, lahan basah, dan kelas tanaman minor—diubah menjadi kelas *background* (nilai 0).

3.5 Pelatihan Model

3.5.1 Penerapan Attention Mechanism

Pelatihan model *semantic segmentation* menggunakan DeepLabV3+ dan SegFormer. Untuk DeepLabV3+, ditambahkan *Convolutional Block Attention Module* (CBAM) setelah ASPP (Hsu et al., 2022). SegFormer menggunakan *Self-Attention* bawaan (Xie et al., 2021).

3.5.2 Skenario Pelatihan

Skenario pelatihan meliputi:

1. **Single Band Single date**: Setiap band dilatih terpisah pada tanggal tertentu.
2. **Kombinasi Band Spektral Multi-temporal**: Menggunakan kombinasi GSI tertinggi dan data temporal.

3.5.3 Hyperparameter Tuning

Dilakukan penyesuaian *learning rate*, *batch size*, dan *epoch*.

3.6 Evaluasi

Metrik evaluasi yang digunakan:

- **Overall Accuracy (OA)**: Mengukur proporsi piksel yang benar (Thomas Ramos and Sappa, 2024).
- **Mean Intersection over Union (mIoU)**: Rata-rata IoU seluruh kelas.
- **F1-score**: Rata-rata harmonik precision dan recall.

Dilakukan juga *error analysis* dan pengukuran *inference time*.

Bab 4

HASIL DAN PEMBAHASAN

4.1 Hasil Eksperimen

[Bagian ini akan berisi hasil eksperimen dari pemetaan tanaman pertanian menggunakan model semantic segmentation. Tabel dan grafik hasil akurasi (OA, mIoU, F1-score) akan ditampilkan di sini.]

4.2 Analisis Hasil

[Bagian ini akan membahas analisis dari hasil yang didapatkan. Perbandingan antar model (DeepLabV3+ vs SegFormer), pengaruh kombinasi band, dan analisis kesalahan (error analysis) akan dijabarkan secara mendetail.]

4.2.1 Perbandingan Performa Model

[Diskusi mengenai model mana yang lebih unggul dalam berbagai skenario]

4.2.2 Pengaruh Data Multi-Temporal

[Diskusi mengenai apakah data multi-temporal meningkatkan akurasi dibandingkan single-date]

4.2.3 Analisis Kesalahan

[Visualisasi dan pembahasan mengenai area yang sering salah diklasifikasikan]

Bab 5

KESIMPULAN DAN SARAN

5.1 Kesimpulan

Berdasarkan hasil eksperimen dan analisis yang telah dilakukan, dapat disimpulkan bahwa:

1. *[Kesimpulan 1]*
2. *[Kesimpulan 2]*
3. *[Kesimpulan 3]*

5.2 Saran

Beberapa saran untuk pengembangan penelitian selanjutnya adalah:

- *[Saran 1]*
- *[Saran 2]*

Bibliografi

Ajibola, S. and Cabral, P. (2024). A systematic literature review and bibliometric analysis of semantic segmentation models in land cover mapping. *Remote Sensing*, 16(12):2222.

Alami Machichi, M. et al. (2023). Crop mapping using supervised machine learning and deep learning: a systematic literature review. *Int J Remote Sens*, 44(8):2717–2753.

Chang, Z. et al. (2023). Crop type identification using high-resolution remote sensing images based on an improved deeplabv3+ network. *Remote Sens (Basel)*, 15(21):5088.

Chen, L.-C. et al. (2018). Encoder-decoder with atrous separable convolution for semantic image segmentation. *arXiv preprint arXiv:1802.02611*.

Cheng, X. et al. (2023). Application of deep learning in multitemporal remote sensing image classification. *Remote Sens (Basel)*, 15(15):3859.

Copenhaver, K. et al. (2021). Examining the characteristics of the cropland data layer in the context of estimating land cover change. *ISPRS Int. J. Geo-Inf.*, 10(5):281.

Gao, M., Lu, T., and Wang, L. (2023). Crop mapping based on sentinel-2 images using semantic segmentation model of attention mechanism. *Sensors*, 23(15):7008.

Hsu, C.-Y. et al. (2022). Improving the deeplabv3+ model with attention mechanisms applied to eye detection and segmentation. *Mathematics*, 10(15):2597.

Li, G. et al. (2023a). Multi-year crop type mapping using sentinel-2 imagery and deep semantic segmentation algorithm in the hetao irrigation district in china. *Remote Sensing*, 15(4):875.

Li, Q., Tian, J., and Tian, Q. (2023b). Deep learning application for crop classification via multi-temporal remote sensing images. *Agriculture*, 13(4):906.

Li, Z. et al. (2023c). Multi-year crop type mapping using sentinel-2 imagery and deep semantic segmentation algorithm in the hetao irrigation district in china. *Remote Sensing*, 15(4):875.

Luo, Z. et al. (2024). Semantic segmentation of agricultural images: A survey. *Information Processing in Agriculture*, 11(2):172–186.

Maleki, R. et al. (2024). Refinement of cropland data layer with effective confidence layer interval and image filtering. *Agriculture*, 14(8):1285.

Niu, Z., Zhong, G., and Yu, H. (2021). A review on the attention mechanism of deep learning. *Neurocomputing*, 452:48–62.

Phiri, D. et al. (2020). Sentinel-2 data for land cover/use mapping: A review. *Remote Sensing*, 12(14):2291.

Potapov, P. et al. (2022). Global maps of cropland extent and change show accelerated cropland expansion in the twenty-first century. *Nature Food*, 3(1):19–28.

Seydi, S. T., Amani, M., and Ghorbanian, A. (2022). A dual attention convolutional neural network for crop classification using time-series sentinel-2 imagery. *Remote Sens (Basel)*, 14(3):498.

Thomas Ramos, L. and Sappa, A. D. (2024). Multispectral semantic segmentation for land cover classification: An overview. *IEEE J. Sel. Top. Appl. Earth Obs. Remote Sens.*, 17:14295–14336.

Thorp, K. R. and Drajat, D. (2021). Deep machine learning with sentinel satellite data to map paddy rice production stages across west java, indonesia. *Remote Sens Environ*, 265:112679.

Tran, K. H. et al. (2022). 10 m crop type mapping using sentinel-2 reflectance and 30 m cropland data layer product. *Int. J. Appl. Earth Obs. Geoinf.*, 107:102692.

Wang, L. et al. (2023). Histogram matching-based semantic segmentation model for crop classification with sentinel-2 satellite imagery. *GIsci Remote Sens*, 60(1).

Weiss, M., Jacob, F., and Duveiller, G. (2020). Remote sensing for agricultural applications: A meta-review. *Remote Sens Environ*, 236:111402.

Wu, Y., Tang, L., and Yuan, S. (2025). Semantic segmentation model of multi-source remote sensing images was used to extract winter wheat at tillering stage. *Scientific Reports*, 15(1):14751.

Xie, E. et al. (2021). Segformer: Simple and efficient design for semantic segmentation with transformers. *arXiv preprint arXiv:2105.15203*.

Yi, Z., Jia, L., and Chen, Q. (2020). Crop classification using multi-temporal sentinel-2 data in the shiyang river basin of china. *Remote Sensing*, 12(24):4052.

Yuan, Y. and Lin, L. (2021). Self-supervised pretraining of transformers for satellite image time series classification. *IEEE J Sel Top Appl Earth Obs Remote Sens*, 14:474–487.

Zhao, J. et al. (2020). A robust spectral-spatial approach to identifying heterogeneous crops using remote sensing imagery with high spectral and spatial resolutions. *Remote Sens Environ*, 239:111605.